

2025년 **다마** 스터디 [후기]

현종열

김영준

이규효

현종열

박동근

변유철

[목차]

1. 건설공사 사고 예방 및 대응책 생성 : 한솔데코 시즌3 생성 AI 경진대회 
2. 제 4회 ETRI 휴먼이해 인공지능 논문경진대회 

건설공사 사고 예방 및 대응책 생성 : 한솔데코 시즌3 생성 AI 경진대회

1. 대회 소개
2. 데이터 소개
3. 단머스 스터디 자료 공유
4. 대회 1등 자료 공유
5. Lesson Learned 공유

건설공사 사고 예방 및 대응책 생성 : 한솔데코 시즌3 생성 AI 경진대회

알고리즘 | NLP | 생성형 AI | LLM | MLOps | 유사도

₩ 상금 1,000만 원

🕒 2025.02.17 ~ 2025.03.24 09:59

+ Google Calendar

👤 1,374명 📅 마감



참여중

[배경]

한솔데코는 지속적인 혁신과 기술 개발을 통해 건축 자재 및 안전 관리 분야에서 선도적인 위치를 더욱 공고히 하고자 합니다. 인공지능(AI) 기술을 접목하여 건설 현장의 안전성을 강화하고, 사고 예방 및 대응 체계를 고도화하는 데 주력하고 있습니다. AI의 활용은 건설 현장에서 발생하는 사고 사례를 체계적으로 분석하고, 효과적인 대응책을 자동으로 생성하여 보다 안전한 작업 환경을 조성하는 데 기여할 것입니다.

- 한솔데코 당사 홈페이지 [링크](#)

지난 [시즌1 경진대회](#)에서는 이미지 데이터를 활용한 도배 하자 유형 분류 AI 모델을 개발하는 데 집중하였으며, [시즌2 경진대회](#)에서는 한 걸음 더 나아가 NLP(자연어 처리) 기반의 QA 시스템을 통해 도배 하자 관련 질의응답이 가능한 AI 모델을 개발하였습니다.

이번 [시즌3 경진대회](#)에서는 건설공사 사고 상황 데이터를 기반으로 사고 원인을 분석하고, 재발방지 대책 및 향후 조치 계획을 자동으로 생성하는 AI 모델을 개발하는 것이 목표입니다. 참가자들은 실제 사고 데이터를 학습하여 건설 현장의 사고 대응 역량을 향상시키고, 효과적인 안전관리 프로세스를 구축하는 AI 기술을 연구하게 됩니다.

이 대회는 AI를 활용하여 건설 현장의 사고 예방 및 대응책 수립을 혁신할 수 있는 기회를 제공합니다.

한솔데코와 함께 건설공사의 더 안전한 미래를 만들어 갈 여러분의 도전을 기다립니다.

[주제]

건설공사 안전사고 대응 및 재발방지 대책 AI 모델 개발

건설사고 재발방지 대책

[설명]

건설공사 사고 상황 데이터를 바탕으로 사고 원인을 분석하고 재발방지 대책을 포함한 대응책을 자동으로 생성하는 AI 모델을 개발해야 합니다.

생성형 AI 모델 개발

1. 문제 정의 및 데이터 설명

건설공사 도메인 Question Answering

- 건설공사 사고 상황 데이터를 바탕으로 사고 원인을 분석하고 재발방지 대책을 포함한 대응책을 자동으로 생성하는 AI 모델을 개발하고자 함.
- 학습 데이터는 23,422 건의 사고 상황에 대한 train.csv 파일과 104 개의 건설안전지침 pdf 파일임.
- 평가 데이터는 964 건의 사고 상황에 대한 test.csv 파일임.
- 발생일시, 사고인지 시간, 날씨, 기온, 습도, 공사종류, 연면적, 층 정보, 인적사고, 물적사고, 공종, 사고객체, 작업프로세스, 장소, 부위, 사고원인 등의 변수는 질문 및 검색에 활용될 수 있음.

건설공사 사고 상황 Question Answering 데이터셋 예시

발생일시	...	인적사고	...	공종	...	사고원인	재발방지대책 및 향후조치계획
2023-12-31 오후 12:44		떨어짐(5미터 이상 ~ 10미터 미만)		건축 > 철근콘크리트공사		고소작업 중 추락 위험이 있음에도 불구하고, 안전난간대, 안전고리 착용 등 안전장치가 미흡하였음.	고소작업 시 추락 위험이 있는 부위에 안전장비 설치.
2023-12-30 오후 03:35		깨임		토목 > 터널공사		부주의	재발 방지 대책 마련과 안전교육 실시.
2023-12-30 오후 02:30		넘어짐(미끄러짐)		건축 > 철근콘크리트공사		3층 슬라브 작업시 이동중 미끄러짐	현장자재 정리와 안전관리 철저를 통한 재발 방지 대책 및 공문 발송을 통한 향후 조치 계획.

1. 리더 보드

· 평가 산식

1. S-Bert Cosine Similarity (CosineSim)

$$\text{CosineSim}(\mathbf{v}_{gt}, \mathbf{v}_{pred}) = \frac{\mathbf{v}_{gt} \cdot \mathbf{v}_{pred}}{\|\mathbf{v}_{gt}\| \|\mathbf{v}_{pred}\|}$$

2. Jaccard Similarity (JaccardSim)

$$\text{JaccardSim}(T_{gt}, T_{pred}) = \frac{|S_{gt} \cap S_{pred}|}{|S_{gt} \cup S_{pred}|}$$

3. 최종 평가 점수

$$\text{Score} = \frac{1}{N} \sum_{i=1}^N (0.7 \times \max(\text{CosineSim}_i, 0) + 0.3 \times \max(\text{JaccardSim}_i, 0))$$

여기서,

- N : 평가 샘플 개수
- CosineSim : S-Bert 기반 코사인 유사도 점수
- JaccardSim : 자카드 유사도 점수

※ S-Bert Cosine 유사도는 예측(생성) 문장과 정답 문장간의 의미론적 유사성을 측정합니다.


※ S-Bert Cosine 유사도에 활용되는 정답(GT)의 Embedding Vector는 'jhgan/ko-sbert-sts' 모델을 통해 추출되었습니다.

※ Jaccard 유사도는 예측(생성) 문장과 정답 문장에서 사용된 단어들의 집합을 비교하여 어휘적 유사성을 측정합니다.


※ S-Bert Cosine 유사도에 활용되는 Embedding Vector는 반드시 Jaccard 유사도에 활용되는 Text이어야 합니다.

중요 변수별 학습, 검증, 테스트 데이터의 분포를 비교하여 테스트 데이터와 가장 분포가 유사한 검증 데이터 생성


{공사종류}




{장소}




{부위}



{사고원인}




{작업 프로세스} 학습, 검증, 테스트 분포 비교



검증 데이터셋을 통해 모델 성능평가 테스트 진행

모델 성능평가 향상 시 제출, 성능 개선이 없는 경우 오차 분석을 통해 추가 실험 계획 수립 (반복 작업)



예측값 중 고득점 샘플과 저득점 샘플을 랜덤으로 샘플링 하여 정성평가 진행
개선 포인트 발굴 후 실험 설계(데이터 전처리 수정 또는 프롬프트 수정)에 활용

점수 : 0.48298144340515137


사고원인: 고속절단기가 정지하지 않은 상태에서 목재 제거를 시도하여 발생. (고속절단기 사용방법의 미숙)

인적사고: 절단, 베임

키워드 : 미숙, 베임, 절단, 지하, 철근


실제값 : 고속절단기 날의 회전이 완전히 멈춘 후 목재를 제거할 수 있도록 하는 안전교육 실시.

예측값 : 고속절단기 사용방법 교육 강화와 작업 중 장비 정지 절차 준수를 통한 재발 방지 대책 및 향후 조치 계획.



오타 분석을 통해 중요 키워드 발굴

중요 사고 키워드 구축 후 데이터 전처리 및 프롬프트에 사고 키워드 활용



#	키워드1	키워드2	키워드3	키워드4	키워드5
1	넘어짐	안전로프	찢림	미흡	거꾸집
2	미끄러짐	로프	화상	안전장치	지게차
3	헛디딤	앙카	용접	추락	양중
4	떨어짐	안전망	교통사고	타박	난간대
5	2인 1조	물체에 맞음	신호	강풍	안전 로프
6	안전 발판	끼임	교통	결빙	안전 고리
7	우마	협착	신호위반	피로	덮개
8	틀비계	조임	감전	쓰러짐	TBM
9	안전대	압착	누전	불안전	지붕
10	크레인	끼여	절연	과도한	지하
11	해체	부딪힘	전기	운반	계단
12	안전화	절단	질식	이동	낙하물
13	작업발판	베임	부주의	산업재해	철근
14	비계	그라인더	과실	바닥	굴착기
15	사다리	고속절단기	실수	평탄화	그물망
16	안전난간	드릴	과오	안전커버	망치
17	3미터	깔림	단순	미착용	손가락
18	고소작업대	질병	주의태만	고정	손바닥
19	안전벨트	근골격계	관리소홀	과적재	고소작업차
20	안전모	허리	미숙	중량물	파열

사고 키워드를 프롬프트 context에 제공하여 LLM이 사고 키워드를 기반으로 재발방지대책을 답변하도록 유도
오차 분석

사고 키워드
사전



점수 : 0.41305050253868103

사고원인: 크레인 해체를 위하여 붐대를 지면에 내리고 작업자가 보조붐대 연결핀 제거 과정에서 붐대 지지대가 전도되어 크레인
고가 발생함

인적사고: 물체에 맞음

키워드 : 물체에 맞음, 바닥, 미동, 추락, 크레인, 해체, 협착

실제값 : 조립 해체가 수반되는 모든 장비에 대한 조립 해체계획서 작성 및 건설관리사업자 승인 의무화와 관련법령 개정 건의.

예측값 : 작업 전 안전교육 실시와 크레인 해체 과정에서 붐대 지지 및 안전점검 철저 지시, 신호수 배치와 작업자 협력 강요소
재발 방지 대책 마련.

⚠️ 사고 키워드 (중요!!) 🚨🚨🚨

※ 활용 가이드 :

- 1) 아래 '사고 키워드'는 사고정보 중 중요한 정보를 추출한 정보입니다. '사고 키워드'를 활용해서 답변하세요.
- 2) '사고 키워드' 개수에 따라서 답변 길이 조정 가능합니다.


- 사고 키워드 : {row['사고중요키워드모음']}

위의 정보를 바탕으로, 해당 사고의 '재발방지대책 및 향후조치계획' 을 제시해 주시기 바랍니다.

"""

사고 키워드 사전을 활용해서 사고원인을 유형별로 분리

유형별 재발방지대책 코사인 유사도를 산출해서 점수가 높은 TOP5 추출 후 정성평가를 통해서 TOP3 선정 후 프롬프트에 활용



- ✅ 사고유형 : 결빙
- 1 사고 비율: 1.79%
- 2 [결빙] 유사어 또는 동명어: 한파, 눈, 빙판
- 3 [결빙] 사고는 아래 조건에서 많이 발생:
 - [인적사고]가 넘어짐(미끄러짐)(28.6%, 평균대비 19.2%p 상승) , 물체에 맞음(25.0%, 평균대비 10.2%p 상승) , 기타(12.4%, 평균대비 4.2%p 상승) , 찰림(9.0%, 평균대비 7.7%p 상승)
 - [사고객체(대분류)]가 기타(33.8%, 평균대비 14.2%p 상승)인 경우.
- 4 [결빙] 사고유형의 재발방지대책 (베스트 답변 유형):
 - 결빙구간 제거와 사고사례에 따른 재발방지교육 실시 및 동절기 작업 전 결빙구간 확인 후 위험요소 제거와 안전교육 실시.
 - 제설작업 및 현장 내 결빙구간 제거, 근로자 아이젠 지급, 현장 근로자 안전사고 예방 교육 철저 통보를 포함한 재발 방지 대책.
 - 안전교육과 결빙부분 해소를 통한 재발 방지 대책 및 현장 관리 철저와 지속 모니터링을 포함한 향후 조치 계획.

배경 : 현장의 외래어 표기 방법과 오타는 RAG로 가져올 **건설안전지침**의 표현과 다르고, 특수한 도메인이기 때문에 이들을 LLM이 구분하기 어려울 수도 있을 것으로 보임

목표 : 오타/유사어 사전 생성

알고리즘 : difflib.SequenceMatcher

1. 두 시퀀스에서 가장 긴 공통 시퀀스를 찾음
2. 그 부분을 기준으로 좌우로 나눔
3. 나뉜 좌우 시퀀스에서도 같은 방식으로 재귀
4. 이 과정을 반복하여 전체 유사도 계산

향후 방향 : 자연어 이해 모델을 finetuning하여 오타, 유의어 처리 모델 배포/관리

구현 방법

1. 이전 사례 데이터셋(DataFrame) flatten
2. 각 value들에 대해 형태소 분석기(Open Korean Text)로 조사, 동사, 형용사 제거
3. 각 어절을 공백 기준으로 split 후 set으로 저장(중복 제거)

```
{'부딪히거',  
'유자격자',  
'파단',  
'정밀',  
'과압',  
'불량임',  
'한국전력공사',  
'균형감각',  
'주변장물',  
'자동릴형',  
'제빙작업',  
'일시보관',  
'한계하중'
```

만들어진 set

구현 방법

4. set에 저장된 값들의 각 음절을 자모음 단위로 분해

5. 유사도 사전을 만든 후, set에 저장된 모든 값에 대해 difflib.SequenceMatcher를 사용하여 유사도 사전에 유사 단어가 없을 시 key 추가

- 유사도 비교 도구로 difflib.SequenceMatcher 사용

6. 만들어진 유사도 사전에서 사람이 직접 의도 파악 후 외래어 표기와 오타를 구분하여 수정

```
"골착토사": [
    "골착토사"
],
"귀볼": [
    "귓볼"
],
"그라이더": [
    "그라인더"
],
"글라인드": [
    "그라인더"
],
"글라인더": [
    "그라인더"
],
```

만들어진 유사도 사전


```
"골착토사": "골착토사",
"과상승방봉": "과상승방지봉",
"관리담독": "관리감독",
"관정에서": "과정에서",
"교용노동부": "고용노동부",
"굴착잡업": "굴착작업",
"귀볼": "귓볼",
"그라스울": "글라스울",
"그라이더": "그라인더",
"그라인던": "그라인더",
"그라인드": "그라인더",
"그란인더": "그라인더",
"그로자": "근로자",
"근록자": "근로자",
```

수정된 유사도 사전


모델 아키텍처 포인트 : 데이터 탐색을 통해 인사이트 발굴 후 다양한 프롬프트 설계

※ LLM :
Qwen/Qwen2.5-14B-Instruct-1M,
Qwen/Qwen2.5-32B-Instruct-1M

※ 임베딩 모델 :
jhgan/ko-sbert-sts



인사이트를 활용해서 다양한 정보 생성 후 프롬프트로 제공하는 전략을 사용



사고원인사전을 활용하여 사고원인별 답변 추천 단어 제공

지침

사고원인사전

사고원인별
답변 추천 단어

Context

◀ 지침: 당신은 건설현장 베테랑 안전 전문가입니다.

지침

- 사고 유형별 재발방지대책을 작성하시오.
- 한 문장만 작성하며, 불필요한 단어 포함 금지.
- 줄바꿈 없이 작성하고, 중복 내용 제거.
- 지침 내용 복사 금지, 답변 외 다른 설명 금지.
- 존댓말 사용 금지.
- 답변 작성 시 아래 내용을 참고하시오 (중요도개수: 🚩)
- 1. 사고원인 : 사고원인유형(🚩🚩🚩), 사고원인(🚩🚩), 인적사고(🚩)
- 2. 답변 예시(🚩)
- 3. 표준재발방지대책(🚩)
- 4. 사고원인별 답변 추천 단어 (🚩)

{context}

추천 단어

▲ 사고원인별 답변 추천 단어 (추천단어를 활용해서 답변을 생성하세요.)

- 작업자의 부주의 or 작업자의 과실 -> 작업 전 안전교육 실시. 안정관리 안전점검 실시.
- 사고원인이 없는 경우 or 조사 중 -> '작업전 안전교육 강화 및 작업장 위험요소 점검을'
- 떨어짐 (2미터 미만) -> '2인 1조', '발판', '안전고리', '우마'
- 떨어짐 (2미터 이상 ~ 3미터 미만) -> '비계', '안전발판', '사다리', '안전난간'
- 떨어짐 (3미터 이상 ~ 5미터 미만) -> '고소작업대', '안전고리', '안전벨트', '디더'
- 떨어짐 (5미터 이상 ~ 10미터 미만) -> '안전모', '안전난간', '안전로프'
- 떨어짐 (10미터 이상) -> '로프', '양카', '안전망'

사고 정도 이외에 사고원인사전을 활용하여 사고 중요 키워드 제시

사고 정보

사고원인사전

중요 키워드

Context

질문:

📌 공사 정보:

- 공사종류: 대분류 '토목', 중분류 '터널', 소분류 '철도터널'
- 공종: 대분류 '토목', 중분류 '터널공사'

📌 사고 정보:

- 사고객체: 대분류 '건설자재', 중분류 '볼트'
- 작업 프로세스: '운반작업'
- 사고 원인: '부주의'
- 사고 원인 카테고리: '끼임, 부주의, 작업자부주의'
- 사고 유형 분류 (인적사고): '끼임'
- 사고 유형 분류 (물적사고): '없음'

사고 키워드

📌 사고 발생 장소:

- 위치: 대분류 '철도터널', 중분류 '내부'
- 부위: 대분류 '볼트', 중분류 '바닥'
- 층 정보: '-', 'None'

📌 환경 조건:

- 기온: '10℃'도
- 날씨: '맑음'

사고원인 사건을 활용하여 사고를 유형화하고 유사도 점수가 가장 높은 유형별 표준 재발방지대책 추출 후 프롬프트 내 정보 제공

표준 재발방지대책

카테고리별
모범답변예시 (정적)

사고원인사건

Context

◀ 이번 사고에 대한 과거 답변 기록 (※ 답변 힌트, 재해방지대책 작성 시 참고, 모범

- 고소작업 시 추락 위험이 있는 부위에 안전장비 설치.

◀ 표준 재발방지대책:

표준 재발방지대책

✅ 사고유형: 결빙

- 결빙구간 제거와 사고사례에 따른 재발방지교육 실시 및 동절기 작업 전 결빙구간 확인 후
- 제설작업 및 현장 내 결빙구간 제거, 근로자 아이젠 지급, 현장 근로자 안전사고 예방 교육
- 안전교육과 결빙부분 해소를 통한 재발 방지 대책 및 현장 관리 철저와 지속 모니터링을

✅ 넘어짐(미끄러짐)

- 이동식 사다리 및 비계 아웃트리거 설치
- 작업자 건강 상태 확인 및 작업 전 스트레칭 실시
- 우천 시 작업구간 배수 조치 및 방수 포장 적용
- 이동식 비계 작업 시 안전벨트 고리 체결 의무화
- 미끄럼 방지 강화 및 보호장구 착용 의무화

✅ 넘어짐(물체에 걸림)

- 전선 및 배관 정비 및 보호관 설치
- 전도 위험 자재 (철근, 목재 등) 보호커버 설치
- 작업 전 공사용 자재 정리정돈 및 구획 설정
- 야적장 내 자재 배치 개선 및 이동 동선 확보
- 작업 중 이동통로에 적재 금지 및 즉각 정리

유사도 기반 사고 유형별 모범답변 TOP5를 추출하고 이중 정성평가를 진행하여 사고 유형별 모범답안 선정 후 프롬프트 내 정보 제공

사고유형별
모범답변예시

카테고리별
모범답변예시 (동적)

사고원인사전

Context

사고 유형별 답변 예시:

사고 유형별 답변

✓ 사고유형 : 넘어짐(미끄러짐)

1 사고 비율: 9.34%

4 [넘어짐(미끄러짐)] 사고유형의 재발방지대책 (베스트 답변 유형):

- 이동통로 확보 관리와 작업 전 안전교육 철저 및 정기적 근로자 안전교육 시행을 통한
- 작업전 이동통로 및 작업환경 점검, 안전교육 강화와 안전예찰 강화를 포함한 재발 방

✓ 사고유형 : 넘어짐(물체에 걸림)

1 사고 비율: 6.36%

4 [넘어짐(물체에 걸림)] 사고유형의 재발방지대책 (베스트 답변 유형):

- 현장 정리정돈 실시와 작업 전 안전교육 철저를 통한 재발 방지 대책 및 향후 조치 계
- 작업 전 안전교육 및 사고 사례 교육 실시와 현장 내 작업 전후 안전교육 및 정리 정돈


✓ 사고유형 : 넘어짐(기타)

1 사고 비율: 8.81%

4 [넘어짐(기타)] 사고유형의 재발방지대책 (베스트 답변 유형):

- 작업전 안전교육 실시와 안전관리자 안전점검 실시를 통한 재발 방지 대책 및 향후 조
- 안전교육 실시와 작업 중 안전관리 철저를 통한 재발 방지 대책 및 향후 조치 계획. (


상관관계가 낮고 valid 점수가 높음 4개 모델 선별 후 양상블 모델 개발 후 최종 모델로 제출



2. 언어 모델 추론 방법론

Prompt Engineering

- User Message는 제공된 유사 사고사례를 통한 합리적인 추론 과정과 명확한 출력의 답변 생성을 목적으로 설계함.
 - 유사도 계산을 통해 train.csv에서 5가지 유사 사고 사례를 전달함.
 - 유사 사례와 사고 상황을 모두 참고하여 구체적이고 종합적인 대책을 생성하도록 유도함.
 - “하나씩 차근차근 생각한 뒤...”(Zero-shot CoT)로 노이즈가 강한 데이터에서 모델의 추론 성능을 최대한으로 향상시킴.
 - “대응대책:”으로 시작하는 출력 형식을 명확히 지정하여 일관성 있는 답변을 출력하도록 지시함.




2. 언어 모델 추론 방법론


Chain of Thought 기반 LLM

- 알리바바 클라우드의 오픈 소스 언어 모델 Qwen 시리즈의 추론 특화 LLM인 QwQ-32B를 사용함.
- QwQ는 CoT 기법과 강화학습으로 최적화된 LLM으로 DeepSeek-R1, OpenAI-o1-mini 등 state-of-the-art 모델과 비교 시 적은 파라미터로 우수한 사고 및 추론 능력을 보임.
- QwQ-32B 모델을 기반으로 QLoRA를 활용한 4비트 양자화를 적용하여 단일 RTX3090 환경에서도 서빙 가능성을 확인함.
- 추론 시 CoT 기법의 <think> 태그를 추출하여 건설공사 사고 상황에 대한 사고 원인을 분석하고 대응책 답변을 해석할 수 있음.

CoT 기반 LLM 성능 비교




추론 시 <think> 태그 출력 예시



2. 언어 모델 추론 방법론

LLM 비교 실험 정성적 평가

- QwQ-32B와 비교 실험을 위해 'Phi-4'는 14B으로 미세 조정을 적용하였고, 'Gemma-3'는 27B으로 CoT 기반 학습 없이 instruction tuning만 수행된 모델임.
- 예를 들어, 사고 원인으로 '강한바람이 불어 천막 고정용 로프에 맞음'에 대한 대응책을 살펴보면 Phi-4에 비해 Gemma-3와 QwQ가 우수한 답변을 생성하는 것을 확인함.
- Phi-4를 통해, 현재 구축된 학습 데이터로 LLM을 미세 조정하면 답변의 품질이 떨어지는 것을 정성적으로 확인함.
- Few-shot Prompting을 통해, 사고 상황 정보 변수들을 참고해서 정보량이 풍부하고 유의미한 문장을 생성하는 것을 확인함.



2. 언어 모델 추론 방법론

LLM 비교 실험 정성적 평가

- Gemma-3는 QWQ와 달리 CoT 기반 방식으로 학습되지 않아 사고 추론 과정을 확인할 수 없음.
- 때문에, QWQ가 Gemma-3에 비해 해석 가능성 측면에서 강점을 가짐.
- 예시를 살펴보면, QWQ는 각 사고의 원인과 대응 방안을 단계적으로 설명하며 논리적인 판단 흐름을 제공함.

QWQ의 Chain-of-Thought 추론 과정

<think>

좋아, 이제 기존 사고에 대한 재발방지 대책과 향후 조치 계획을 만들어야 하는데, 우선 기존 사고를 자세히 살펴봐야겠다.
기존 사고는 철근콘크리트 공사 중 양생작업 시 강한 바람으로 인해 천막 고정 로프에 맞았다는 거네. 장소는 근린생활시설의 외부이고, 부위는 상부(위)야.
먼저 유사 사례들을 하나씩 비교 분석해야 할 것 같아. 각 사례들의 공통점과 차이점을 찾아봐야지.

첫 번째 유사 사례는 공동주택 내부에서 마감작업 중 돌등으로 천막이 넘어진 경우인데, 대응책은 안전교육 강화였어. 이긴 바람 관련된 문제고, 같은 철근콘크리트 공종이라서 **관련성**이 있겠지.
두 번째 사례는 양생작업 중 겨울철 강동으로 천막을 잡던 중 통풍이 생긴 경우야. 대응책은 작업 전 교육과 계절적 날씨에 따른 작업 중지를 포함했어. 이건 기존 사고와 같은 양생작업,
그리고 바람의 영향이므로 **매우 유사해 보여**.
세 번째는 결빙된 바닥에서 미끄러진 경우인데, 장소가 외부라서 관련성이 조금 낮을 수도 있지만 안전교육과 제설 작업이 포함됐어. 하지만 기존 사고는 바람과 천막 문제라서 **다른 요인이네**.
네 번째는 계단 근처 발판 미끄러짐으로 추락한 사례인데, 장소가 외부이고 상부 부위와 관련되어 있지만 원인은 미끄러짐이라 **차이가 있어**. 대응책은 안전교육과 보호장비 확인이었어.
다섯 번째는 알몸이 바람에 넘어져서 타격을 입은 경우야. 설치작업 중인데, 천막 관련보다는 다른 구조물의 이동 문제지만 바람 영향으로 인한 사고라는 점에서 **유사해 보여**.
대응책에는 작업장 동선 확보와 몸풀기, 관리자 지도가 있었어.

이제 기존 사고의 핵심 요소는 '강풍', 천막 고정 로프 관련, 양생작업 중 외부 상부 작업이라는 점을 생각해야 해.
유사한 사례들에서 강조된 대응책은 안전 교육, 계절적 날씨에 따른 작업 조치(특히 바람이 심할 때는 작업 중지), 천막 고정 방법 개선, 관리자의 상주 감독 등을 볼 수 있네.
두 번째 사례의 경우 강풍 시 작업 중지를 명시했고, 교육과 함께 감독자 관리도 포함되어 있으니 참고해야겠어.
또한 다섯 번째 사례에서는 구조물 고정 중요성을 언급했으니까 천막 설치 방법을 검토하고 고정 장비를 강화하는 것도 좋을 것 같아.
결론적으로, 기존 사고는 바람으로 인한 천막 로프 타격이니, 바람 강도 모니터링과 조치(특히 작업 중지 시기), 천막 설치 방법 개선 및 고정 장비 강화, 그리고 교육을 강화하는 게 필요할 거야.
또한 관리자가 현장에서 실시간으로 감독하는 것도 중요하겠지.
이제 이것들을 종합해서 대응대책을 한 문장으로 정리해야 해. ""대응대책:""으로 시작하고, 핵심 요소를 포함시키자.
</think>

4. 도메인 특화 평가 지표 설계

코사인 유사도 & 자카드 유사도 한계점

- 기존 평가 지표로 예측(생성) 문장과 정답 문장 간의 코사인 유사도와 자카드 유사도의 가중 평균을 사용함.
- 코사인 유사도는 의미론적 유사성을 측정하며, 자카드 유사도는 사용된 단어들의 집합을 비교하여 어휘적 유사성을 측정함.
- 기존 평가 지표는 사고 원인에 대한 생성된 답변의 문맥을 반영하지 못하고 자연스러운 문장의 생성을 표현하지 못함.
- 기존 평가 지표는 정량적 평가를 못하기 때문에 건설공사 도메인에 특화된 추가 평가 지표를 설계함.

기존 평가 지표

$$\text{CosineSim}(v_{gt}, v_{pred}) = \frac{v_{gt} \cdot v_{pred}}{\|v_{gt}\| \|v_{pred}\|}$$

$$\text{JaccardSim}(T_{gt}, T_{pred}) = \frac{|S_{gt} \cap S_{pred}|}{|S_{gt} \cup S_{pred}|}$$

$$\text{Score} = \frac{1}{N} \sum_{i=1}^N (0.7 \times \max(\text{CosineSim}_i, 0) + 0.3 \times \max(\text{JaccardSim}_i, 0))$$

기존 평가 지표의 한계점 예시

GT : '동일한 사고가 발생하지 않도록 안전교육 실시'

Pred1 : '동일한 사고가 발생하도록 안전교육 미실시'

Pred2 : '안전교육 실시를 통한 재발 방지 대책 및 향후 조치 계획'

$\text{CosineSim}(GT, \text{Pred1})$: 코사인 유사도가 약 0.86로 매우 높음.

$\text{JaccardSim}(GT, \text{Pred2})$: 자카드 유사도가 약 0.07로 매우 낮음.

4. 도메인 특화 평가 지표 설계

Hazard Analysis & Normalized Safety Optimization Level

- 도메인 특화 평가 지표로 **Hazard Analysis & Normalized Safety Optimization Level(HANSOL)**를 제안함.
- HANSOL score 2가지 구성 요소(Sentiment, Accident)의 가중 평균으로 정의됨.
- Sentiment(S)는 '사고원인'과 생성된 답변이 얼마나 의미론적으로 연관성이 있는지를 평가하는 BERTScore 기반의 지표임.
- S 를 산출하기 위해 Sentence Transformers 라이브러리에서 제공하는 'paraphrase-multilingual-mpnet-base-v2' 모델을 사용하여 <answer> 태그 안의 구문과 '사고원인'의 코사인 유사도를 계산함.
- Accident(A)는 생성된 답변에 사고 상황 정보가 얼마나 포함되었는지 여부를 반영하는 평가 지표임.
- A 은 <answer> 태그 안의 구문에서 '공종(대분류/중분류), 사고객체(대분류/중분류), 작업프로세스, 장소(대분류/중분류), 부위(대분류/중분류)'에 해당하는 키워드의 포함 여부를 측정함.
- 답변에 포함된 키워드 수를 전체 키워드 수로 정규화하여 0에서 1 사이의 값으로 정량화 함.
- HANSOL score는 사고 대응 연관성과 사고 맥락 반영도를 동시에 고려하면서 생성된 '재발방지대책 및 향후조치계획' 품질을 정량적으로 평가할 수 있음.

$$HANSOL(t) = 0.5 \times S(t) + 0.5 \times A(t)$$

4. 도메인 특화 평가 지표 설계

정량적 평가

- 본 연구에서 제안하는 HANSOL 평가 지표를 활용하여 추론 모델을 검증함.
- Gemma3는 Sentiment 점수에서 QWQ보다 좋은 성능을 보이지만, Accident 점수에서 더 낮은 성능을 보임.
- 이는, QWQ 모델이 CoT 추론 과정을 통해 사고 맥락 관련 키워드를 더 잘 반영하여 답변을 생성했기 때문임.
- 본 프로젝트에서 제안하는 QWQ(Few-shot) 모델이 전체적으로 가장 우수한 성능을 보이며 최종 제출 파일로 선정함.

Model	Sentiment	Accident	HANSOL	RANK
QWQ (Few-shot)	0.4983	0.1778	0.3269	1
QWQ (Zero-shot)	0.4100	0.0184	0.2142	4
Gemma3 (Few-shot)	0.5127	0.1146	0.3136	2
Phi4 (Fine-tuned)	0.4991	0.0589	0.2790	3
mean vector	0.3559	0.0001	0.1780	5

Lesson Learned 공유

1. LLM 경진대회는 정량평가가 어렵다.
2. 파인튜닝은 학습 시간이 오래 걸리고 과적합이 쉽게 발생한다. (vLLM 사용 필수)
3. 14B 아래의 모델은 프롬프트 내 지시사항을 100% 따르지 않는다.
4. 케이스별 맞춤형 프롬프트 전략이 효과적이다.
 - 유형별 “필수키워드” 전달
5. 전처리 : 오타, 동의어, 유의어 수정함 (성능 향상 조금)
6. 앙상블 전략 (성능 향상 조금)
 - pred_model1_qwen2.5-14B-1m_score=0.68467.csv
 - pred_model2_qwen2.5-14B-1m_score=0.67723.csv
 - pred_model3_qwen2.5-14B_score=0.67258.csv
 - pred_model4_qwen2.5-32B_score=0.66257.csv
7. 검증 전략 (테스트 데이터셋과 분포가 유사한 데이터셋 선정)



0.6999

제 4회 ETRI 휴먼이해 인공지능 논문경진대회

알고리즘 | 정형 | 라이프로그 | 논문 | 분류 | Macro F1-Score

🏆 상금 : 770만원

🕒 2025.04.21 ~ 2025.07.23 09:59 [+ Google Calendar](#)

👤 1,034명 📅 마감



참여중

[배경]

라이프로그 데이터셋은 인간의 행동과 감정 맥락을 폭넓게 포착할 수 있는 귀중한 연구 자원입니다.

이를 활용함으로써 인간의 복합적인 경험과 심리적 상태, 행동 패턴 등을 분석할 수 있으며, 이를 통해 개인화 서비스나 감성 컴퓨팅 등 다양한 분야에 적용 가능한 기술 발전이 가능해집니다.

제 4회 ETRI 휴먼이해 인공지능 논문경진대회는 이러한 라이프로그 데이터셋을 활용한 연구의 가치를 극대화하고, 인간 이해 연구의 저변 확대를 위한 기반을 마련하고자 기획되었습니다.

[대회 방식]

본 경진대회는 모델 성능 개선을 위한 **1) 리더보드 제출**과 해당 과정을 정리한 **2) 논문 제출**의 두 가지 과정을 모두 수행해야 합니다.

1) 리더보드 제출 : 데이콘 대회 페이지를 통해 예측 결과 파일을 제출하며, 제출된 결과는 평가 산식(Metric)에 따라 채점됩니다. 참가자는 Public 리더보드 점수를 통해 모델 성능에 대한 피드백을 받을 수 있으며, 최종 평가는 Private 리더보드 점수를 기준으로 진행됩니다.

2) 논문 제출 : ICTC 2025(<https://ictc.org/>) 제출 기준을 따르며, 채택된 논문은 ICTC 2025에서 포스터 세션 발표가 이루어집니다.

※ 포스터 세션 발표 및 시상식은 ICTC 2025 학술대회 개최지인 제주도에서 진행되며, 이 외의 일정은 온라인으로 진행됩니다.

※ 4월 21일 오후 2시 온라인 사전 설명회가 진행되었습니다.

• 진행된 내용은 [데이콘 유튜브 페이지](#)에서 확인하실 수 있습니다.

[주제]

라이프로그 데이터를 활용한 수면 품질 및 상태 예측

수면 품질 및 상태 예측

수면의 질

취침 전 피로도

스트레스

[설명]

라이프로그 데이터를 이용한 설문지표(취침 후 수면의 질(Q1), 취침 전 피로도(Q2) 및 스트레스(Q3))와

수면지표(총 수면시간(S1), 수면효율(S2), 수면지연시간(S3))의 예측

총 수면시간

수면효율

수면지연시간

Dataset & Five-Factor Classification

ICTC 2025

International Conference on ICT Convergence

ETRI Lifelog Dataset (Smartphone & Smartwatch Sensors) + **KMA Weather Data** + **Noise-Specific Decibel Data** Integration

Five Factors → Six Sleep Indicators



Physiological

Heart rate
Step count
Distance



Behavioral

Activity patterns
Movement
MET intensity



Digital

Screen usage
App behavior
Connectivity



Environmental

Illumination
Noise (dB)
Weather



Social

Day of week
Weekend
Holidays

Subjective Sleep Indicators

- **Q1:** Overall sleep quality
- **Q2:** Physical fatigue
- **Q3:** Stress level

Objective Sleep Indicators

- **S1:** Total sleep time
- **S2:** Sleep efficiency
- **S3:** Sleep onset latency

1. 리더보드

- 평가 산식 : Macro F1-Score

$$\text{Score} = \frac{1}{6} (F1_{\text{macro}}^{Q1} + F1_{\text{macro}}^{Q2} + F1_{\text{macro}}^{Q3} + F1_{\text{macro}}^{S1} + F1_{\text{macro}}^{S2} + F1_{\text{macro}}^{S3})$$

- Public Score : 전체 테스트 데이터 중 사전 샘플링된 44%
- Private Score : 전체 테스트 데이터 100%

2. 평가 방식

1) 리더보드 평가 (Private 리더보드 Score 100%)

- Private 리더보드 공개 시점 : 최종 Private 리더보드는 공식 시상식 일정까지 비공개로 진행되며, 시상식 종료 후 최종 수상자와 함께 공개됩니다.
- 코드 및 모델 설명서 제출 : 제출한 논문이 Accept된 팀에 한하여 코드 및 모델 설명서를 **제출 규칙(6. 코드 및 모델 설명서 제출 규칙)**에 맞추어 기한 내 제출해야 합니다.

2) 논문 평가 (Accept / Reject)

- ICTC 2025 Workshop Track(ETRI Human Understanding AI Paper Challenge 부문)에 제출된 논문을 대상으로 진행됩니다.
- 기타 논문 제출과 관련된 제반 사항은 ICTC 2025(<https://ictc.org/>) 논문 작성 및 접수 규정을 준수해야 하며, ICTC 2025 논문심의 위원회 평가 방식을 따릅니다.
- 논문이 채택된 참가자는 **10월 16일(목)** 진행되는 포스터 세션 발표에 참여해야 합니다(팀 내 최소 1인 참여 필수). 포스터 발표에 불참하시는 경우 ICTC2025 학회 규정에 따라 논문 게재가 취소됩니다.

※ 논문이 채택(Accept)되고, 기한 내 코드와 모델 설명서를 제출하여 검증에 통과한 후 최종 포스터 세션 발표에 참여한 경우에만 입상 자격이 부여됩니다.

개별 데이터별 전처리 및 파생 변수:

- **mACStatus (충전상태):**
 - 충전 비율, 총 충전 시간, 상태 전환 횟수, 평균/최대 충전 지속 시간 (일별, 수면 시간대별).
- **mActivity (추정행동):**
 - 걷기/차량/활동 시간 (일별, 수면 시간대별).
 - 활동 및 MET(대사 증가) 값의 시간대별 통계 (표준편차, 합계 등)
- **mAmbience (주변소리):**
 - 고유 소리 라벨 수, 코골이(snor) 발생 횟수 (활동/수면 시간대별)
- **mBle (블루투스):**
 - RSSI(신호 강도) 평균/최소/최대, 알 수 없는/기타 기기 비율 (근무/퇴근 후/수면 시간대별)
- **mGps (GPS 위치):**
 - 걷기/조깅/차량 이동 시간, 평균/최대/최소 속도, 이동 거리 (활동/수면 시간대별)
 - 운동 플래그, 첫 기상 시간(분).
- **mLight (주변 밝기):**
 - 일별 밝기 통계 (평균, 표준편차, 최대, 최소, 밤/낮 평균, 밤 비율).
 - 수면/기상 시간, 수면 지속 시간 (밝기 기반 추정).
 - 불 끈 시간 추정.

Resnet embedding Features

◎ 코드명 : [121_etri_lifelog_dm_resnet_embedding_vF.ipynb](#)

◎ 코드 설명 : Resnet50 embedding features 생성 (with PCA 활용)

◎ 사전 작업 :

1) PATH 설정

경진대회에서 제공 된 파일이
저장된 경로로 변경하세요.

```
PATH = '/content/drive/MyDrive/data/ch2025_data_items/share/submissions/input'
```

◎ Info : Google Colab Pro+ 기준, 작업 중간 RAM부족으로 세션 다운 됨 → 세션 재시작 후 모두 재실행 반복 x 5~6회 작업 필요

1차

```
# train: 450
# test: 250
# 전체 데이터 : 700
# 남은 샘플수 : 700
user: id05, date: 2024-09-02: 26% 184/700 [11:00<32:30, 3.78s/it]
```

사용 가능한 RAM을 모두 사용한 후 세션이 다운되었습니다.

Google Colab Pro+ 기준
26% 에서 RAM부족으로 세션
다운 됨

세션 재시작 후
모두재실행하면 마지막 작업
이후로 **이어서** 작업 진행 됨

2차

```
# train: 450
# test: 250
# 전체 데이터 : 700
# 남은 샘플수 : 516
user: id06, date: 2024-06-03: 8% 39/516 [02:19<28:34, 3.59s/it]
```

Resnet embedding Features

ResNet 피쳐 추출 핵심 과정

- **시계열 데이터 이미지 변환:**
 - 라이프로그 시계열 데이터 처리 (특정 시간대(00-06시) 데이터 집중)
 - PNG 이미지 파일 생성.
 - 사용자-날짜별 시계열 채널 그래프화.
- **이미지 전처리:**
 - 생성 이미지 평균/표준편차 계산.
 - ResNet 입력 전 정규화.
 - 이미지 리사이즈(500x500).
 - 평균/표준편차 기반 정규화 적용.
- **ResNet 피쳐 추출:**
 - timm 라이브러리 활용.
 - resnet50 사전 학습 모델 로드.
 - 모델 분류 레이어 제거.
 - 피쳐 추출기 역할 전환.
 - 전처리 이미지 입력.
 - 특징 벡터(임베딩) 획득.
- **피쳐 저장:**
 - 추출 피쳐 PCA 차원 축소(선택) 및 csv 파일 저장

Resnet embedding Features

21:00

06:00



Heart_rate

심박수

M_activity

구글맵(GPS)

step

걸음수

M_light

핸드폰 불빛

W_light

와치 불빛

Resnet embedding Features





Figure 3. Another look at ResNet 34

Resnet embedding Features



Bedtime and Wake Time Inference

Previous studies have shown that **bedtime**, **wake time**, and **total sleep duration** are critical variables for predicting sleep quality. However, these variables were not provided in the dataset and therefore had to be derived from the given sensor data.

Due to the nature of sensor data, noise was present, and **on certain days** the absence of sensor data made it impossible to estimate bedtime, wake time, or sleep duration.

In this competition, only sensor data were provided, information on bedtime and wake time was unavailable. Nevertheless, previous studies have demonstrated that these variables—together with their difference (i.e., sleep duration)—**are critical indicators of sleep quality and stress**.

So we decided to inference bedtime and wake time, sleep duration based on given sensor data.

Bed time / Wakeup time inference procedure

1) Time Window Filtering :

Screen activity records were restricted to the range 21:00–11:00, which typically encompasses the main sleep period.

2) Noise Reduction

Isolated screen-on events within screen-off intervals were removed, and short awake segments (≤ 2 minutes) surrounded by sleep blocks were reclassified as sleep to reduce fragmentation

3) Sleep Block Detection

Continuous screen-off intervals were detected, and the longest interval was designated as the primary sleep episode.


4) Feature Calculation

The start of the longest block was defined as bedtime (21:00–02:00), the end of the block as wake time (03:00–11:00), and their difference as sleep duration (excluded if < 100 minutes).

LLM을 활용한 결측값 추정 (논문 기재 내용)



Despite its potential, lifelog data often suffers from missing values and noise due to the inherent **limitations** of real-world data collection. Even with continuous monitoring via smartphones and smartwatches, missing or anomalous entries frequently occur. This problem is exacerbated by inconsistent device usage—for instance, **users may not wear smartwatches during sleep**—resulting in incomplete or fragmented sleep-related records. Such issues limit the reliability of downstream analyses and predictive modeling.



Evaluation Strategy & Model Results

- ✓ Fair comparison through test-like validation set(valid size : 40) : LLM imputation **outperforms** traditional methods.
- ✓ LLM imputation **improved** performance in all targets except S3.

Comparison of F1 Scores by Different Imputation Methods

Method	F1	Top1 Weights (LGB, XGB, Tab)	Top1 F1
Original	0.6841	(0.1, 0.2, 0.7)	0.6998
Mean Impute	0.6684	(0.2, 0.0, 0.8)	0.7152
KNN Impute	0.6989	(0.2, 0.1, 0.7)	0.7116
LLM Impute	0.7218	(0.3, 0.0, 0.7)	0.7238

TARGET-WISE F1 SCORES

Target	Original	Mean Impute	KNN Impute	LLM Impute
Q1	0.716	0.693	0.697	0.721
Q2	0.780	0.811	0.840	0.840
Q3	0.715	0.680	0.715	0.748
S2	0.670	0.619	0.699	0.775
S3	0.748	0.723	0.723	0.723
S1	0.476	0.484	0.519	0.524

LLM 결측치 보간 핵심 과정:

• LLM 준비:

- vllm 라이브러리 사용.
- 사전 학습된 LLM 모델(Qwen/Qwen3-8B 등) 로드 및 토큰나이저 설정

• 데이터 전처리 및 LLM 입력 준비:

- mScreenStatus 데이터 로드.
- 화면 사용 패턴 기반 취침시간, 기상시간, 수면시간 초기 추정 및 야간/새벽 시간대 필터링
- 짧은 각성/수면 블록 제거로 추정치 정제.
- 시간 값을 소수점 형태로 변환.
- LLM 지침(system_message) 및 사용자 질의(user_message) 프롬프트 구성.
 - 지침: 데이터 분석 전문가 역할, 데이터 설명, 결측치 보간 규칙(유효 범위, 기존 값 유지, 모든 결측치 채우기), 금지 사항 포함.
 - 질의: 특정 사용자 데이터, 통계 정보, 도메인 지식(요일별, 계절별, 전일 상태 영향) 제공.


• LLM 보간 실행:

- 각 사용자별 반복 처리.
- 동적으로 구성된 프롬프트를 LLM에 전달.
- 재시도 메커니즘: LLM 출력에 결측치가 많거나 생성된 행 수가 부족할 경우 최대 3회 재시도 (품질 관리).
- LLM 텍스트 출력 파싱 (탭 구분 테이블).

• 보간 후 처리:

- LLM 보간된 취침시간, 기상시간을 원본 데이터에 병합 (결측치만 채움).
- (보간된) 취침/기상 시간을 기반으로 수면시간 재계산.
- 업데이트된 수면 관련 데이터로 추가 시계열 파생 변수(차이, 비율, 시차, 이동 평균/표준편차) 생성.
- 최종 처리 데이터 및 중간 결과 저장.

Overall Model Framework



✓ LLM-based Imputation

✓ 3 Model Ensemble (TabPFN, LGB, XGB)

모델 학습 및 submission 파일 생성

◎ 코드명 : 200_etri_lifelog_ml_finalmodel_vF.ipynb

◎ 코드 설명 : 최종 모델 학습 및 submission 파일 생성

◎ 모델 학습 :

1) 모델링 전략 (Modeling Strategy)

```
# ... (생략) ...
for col in targets_binary: # Q1, Q2, Q3, S2, S3 루프
    # ... (생략) ...
    # xfeatures1 (SHAP 기반, Q3에만 적용)
    if col in ['Q3']:
        model = XGBClassifier(**xgb_params)
        # ... (생략) ...
        shap_values = explainer.shap_values(X_train)
        # ... (생략) ...
        xfeatures1 = shap_df.head(15)['feature'].tolist()
    else:
        xfeatures1 = []

    # xfeatures2 (상관관계 기반)
    correlations = X.select_dtypes(include=['number']).corrwith(y)
    sorted_correlations = correlations.abs().sort_values(ascending=False)
    xfeatures2 = sorted_correlations[sorted_correlations>0.1].index.tolist()

    # 최종 피쳐셋 조합
    xfeatures_dict[col] = [i for i in X.columns.tolist() if i in set(xfeatures1+xfeatures2)]

    # 선택된 피쳐로 데이터셋 재생성
    X_valid = train_df.loc[train_df['pk'].isin(valid_ids['pk']),xfeatures_dict[col]].reset_index(drop=True).copy()
    X_train = train_df.loc[~train_df['pk'].isin(valid_ids['pk']),xfeatures_dict[col]].reset_index(drop=True).copy()
    # ... (생략) ...
```

- Q3를 예측할 때는 SHAP으로 피쳐 중요도를 계산해 상위 15개를 선택하고(xfeatures1), 타겟 변수와 상관관계가 0.1 이상인 피쳐들(xfeatures2)을 추가로 선택합니다.
- 나머지 타겟들은 상관관계 기반으로만 피쳐를 선택합니다.
- 이렇게 각 타겟(col)마다 다르게 선택된 피쳐 조합(xfeatures_dict[col])을 사용해 모델을 학습시켜 예측 정확도를 높입니다.

모델 학습 및 submission 파일 생성

◎ 코드명 : [200_etri_lifelog_ml_finalmodel_vF.ipynb](#)

◎ 코드 설명 : 최종 모델 학습 및 submission 파일 생성

◎ 모델 학습 :

2) 3가지 모델 앙상블 (Ensemble of 3 Models)

```
# ... (생략) ...
# Train LightGBM
lgb_model = LGBMClassifier(**lgb_params)
lgb_model.fit(X_train, y_train)

# Train XGBoost
xgb_model = XGBClassifier(**xgb_params)
xgb_model.fit(X_train, y_train)

# Train TabPFN
tabpfn_model = TabPFNClassifier(**tabpfn_params)
tabpfn_model.fit(X_train, y_train)

# 검증 데이터셋에 대한 예측 확률 계산
lgb_pred_valid = lgb_model.predict_proba(X_valid)[ :, 1]
xgb_pred_valid = xgb_model.predict_proba(X_valid)[ :, 1]
tab_pred_valid = tabpfn_model.predict_proba(X_valid.values)[ :, 1]

# 가중 평균으로 앙상블
pred_valid = (lgb_A * lgb_pred_valid + xgb_B * xgb_pred_valid + tab_C * tab_pred_valid > 0.5).astype(int)
```

- 세 모델을 각각 학습시키고, 검증 데이터(X_valid)에 대한 예측 확률값을 얻습니다.
- 초기 가중치(lgb_A=0.333, xgb_B=0.334, tab_C=0.333)를 사용하여 예측값들을 합산하고, 임계값(0.5)을 기준으로 최종 클래스를 결정합니다.

모델 학습 및 submission 파일 생성

◎ 코드명 : [200_etri_lifelog_ml_finalmodel_vF.ipynb](#)

◎ 코드 설명 : 최종 모델 학습 및 submission 파일 생성

◎ 모델 학습 :

3) 최적의 앙상블 가중치 탐색 (Finding Optimal Weights)

```
# 0.0부터 1.0까지 0.1 스텝으로 가능한 모든 가중치 조합 생성
step = 0.1
candidates = np.arange(0, 1.1, step)

for lgb_A, xgb_B, tab_C in product(candidates, repeat=3):
    total = lgb_A + xgb_B + tab_C
    if np.isclose(total, 1.0): # 세 가중치의 합이 1.0인 경우만 테스트
        weights = (lgb_A, xgb_B, tab_C)
        val_scores = []

        # Binary targets
        for col in targets_binary:
            # ... (가중치를 적용하여 F1 점수 계산)
            val_scores.append(f1_score(preds['true'], (blended > 0.5).astype(int), average='macro'))

        # Multiclass target
        # ... (가중치를 적용하여 F1 점수 계산)
        val_scores.append(f1_score(preds['true'], np.argmax(blended, axis=1), average='macro'))

        best_weights.append(weights)
        best_scores.append(np.mean(val_scores)) # 6개 타겟의 평균 F1 점수 저장
```

- 세 가중치의 합이 1이 되는 모든 조합(예: 0.1, 0.2, 0.7)을 대상으로 루프를 돌립니다.
- 각 조합을 검증 데이터셋의 예측값에 적용하여 6개 타겟의 평균 F1 점수를 계산합니다.
- 가장 높은 평균 F1 점수를 기록한 가중치 조합을 찾아 저장해 둡니다.

최종 예측 모델:

- 3개 모델 앙상블:
 - LightGBM: Gradient Boosting 모델.
 - XGBoost: Gradient Boosting 모델.
 - TabPFN: 소규모 테이블 데이터 특화 Transformer 모델.

모델 학습 및 검증:


- 검증 전략:
 - 전체 학습 데이터 8.9% (40개 샘플) 검증 세트 분리 및 참가자 별 4개씩 균등 추출.
 - 테스트 데이터와 분포 유사성 확보.
- 결측치 대체 방법론 비교:
 - 4가지 시나리오: (1)결측치 그대로 사용, (2)평균값 대체, (3)KNN 대체, (4)LLM 대체.
 - 동일 3개 모델 앙상블로 예측 성능(F1-Macro) 측정.

성능 평가:

- 전체 성능:
 - LLM 기반 대체: F1 0.7218 (최고).
 - 결측치 그대로 사용 대비 5.5% 성능 향상.
- 지표별 성능:
 - 수면 효율(S2) 지표: LLM 대체 F1 0.775 (압도적).
 - 다른 방법론 대비 약 10%p 향상.
 - LLM의 문맥 이해 및 논리적 추론 능력 입증.
- 앙상블 가중치 최적화:
 - (LGB:0.5, XGB:0.2, TabPFN:0.3) 가중치에서 최고 성능.


Preprocessing & Feature Engineering

- Raw data: Wearable & smartphone lifelog dataset
- Time-series transformation (per sensor, window=3)
 - Rolling statistics: mean, std, median, IQR, MAD
 - Differences & percentage change
 - Expanding mean, EMA
 - Zero-crossing counts
- Aggregation
 - Subject-level features via mean, std, min, max
- Date-based features
 - dayofweek, month, hour, weekend indicator, date_diff
- Final feature set: **779** features (648 time-series + 10 date + others)



Modeling & Training

- Base models: LightGBM, CatBoost (tree-based gradient boosting)
- Training strategy
 - 5-fold stratified cross-validation (to preserve label distribution)
 - Each of 6 targets (Q1-Q3, S1-S3) trained independently
- Ensemble integration
 - LightGBM (30%) + CatBoost (70%) → Soft Voting → Final Prediction
 - Combines LGBM's efficiency & CatBoost's handling of categorical features
- Overfitting prevention: early stopping (30 rounds)
- Hyperparameter Tuning
 - Grid Search




[참고] 대회 1등

#	팀	팀 멤버	점수	제출수	등록일
5	단머스	  	0.63775	166	4달 전
1	LOL	   	0.66852	232	4달 전
2	waniboyy	  	0.66621	274	4달 전
3	마네키네코		0.64627	260	4달 전
4	방_케_필_돈_	   	0.63877	170	4달 전
5	단머스	  	0.63775	166	4달 전
6	뭐 이건 처음부터 다시 키워야 하나	   	0.63266	114	4달 전
7	오리오리나무		0.62966	8	5달 전
8	이탈리안 브레인롯	   	0.62925	219	4달 전
9	sch_csm	 	0.62555	86	4달 전

Lesson Learned 공유

1. Small 데이터, 학습전략

- no stopping rule, iteration = 1000
- no valid dataset use all data for training



DyStack 결과로 최적 구조 확보 후 → 최종 Full 데이터로 스택 학습 진행

2. Small 데이터, 검증전략

- test like valid1 and valid2 (several valid datasets)

3. Magic Features

- 수면시간, 취침시간, 기상시간

4. 이상값 & 결측값 전처리 (이번 경진대회에서 중요했음)